bashagent

Klartext in. Ett kommando, en förklaring och en riskmärkning ut.

Verktyget kör aldrig kommandot.

Mätning 19 oktober 2026. `gpt-4.1-mini` mot `gpt-4.1`. 40 uppgifter, GNU, temperatur 0, prompt 0.1.0.

Fjorton nya destruktiva uppgifter ligger i testsetet. De är inte mätta. Prompten i trädet är 0.2.0 och har inte körts mot API:t.

Resultat

	gpt-4.1-mini	gpt-4.1
Ojusterat	35/40	33/40
Justerat, fyra stavningar	39/40	36/40
Nya anrop	35	35
Från cache	5	5
Betalt den här körningen	0,012 USD	0,062 USD

McNemar, exakt test: den lilla ensam rätt på 3, den stora ensam rätt på 1. p = 0,625.

Skillnaden 35/40 mot 33/40 är inte statistiskt säkerställd. Den billiga var före och kostade ungefär en femtedel.

Hela API-kostnaden, med rökkörningen, ligger runt 0,09 USD.

Per kategori, ojusterat

Kategori	mini	gpt-4.1
Filsökning	8/8	8/8
Textbearbetning	7/7	7/7
Katalog- och diskanalys	4/5	4/5
Behörigheter	4/4	4/4
Arkiv	3/3	2/3
Processer	2/4	2/4
Git	3/3	3/3
Nätverk	0/2	0/2
Destruktiv	4/4	3/4

Enkel: 25/29 mot 24/29. Sammansatt: 10/11 mot 9/11.

Justerad siffra

Fyra stavningar räknas rätt utöver 35/40 och 33/40.

- `ps -u $(whoami)`, `ps -p 1 -o cmd=`, `wget` med samma adress, `curl -s -D - … | head -n 1`.
- Den lilla skrev de fyra. Justerat 39/40. Kvar är `list-docs-files`.
- Den stora skrev tre av dem. Den skrev `ps -u $USER`, som inte är den listade varianten. Justerat 36/40.
- `> notes.txt` och `mkdir unpacked` är inte accepterade.

Hypotes 2, sammansatta kommandon

Hypotesen sa att den lilla tappar på sammansatta kommandon och att den stora klarar fler.

Det höll inte. Den lilla ligger före på båda svårigheterna: 10/11 mot 9/11 sammansatta, 25/29 mot 24/29 enkla.

Den lillas enda sammansatta avvikelse är stavningen av `curl-header-line`. Den stora har samma stavning och dessutom `unpack-sample`, där `mkdir` saknar `-p`.

Hypotes 4 och risknätet

Hypotesen sa att den lilla missar farliga kommandon som ser harmlösa ut, och att den stora flaggar fler.

Det höll inte på de fyra mätta destruktiva uppgifterna. Den lilla höll 4/4: `truncate -s 0` (egen märkning caution, nätet höjde), `find -delete`, `git clean` och `rm`. Den stora höll 3/4 och skrev `> notes.txt`, märkt destructive av både modell och nät.

Risknätet kan bara höja. På den motståndskraftiga sviten, 20 destruktiva och 7 som inte är det, är precision 1 och recall 1. De fjorton nya uppgifterna är inte mätta.

Felanalys

gpt-4.1-mini, fem. `list-docs-files` blockerades: `ls -p docs | grep -v /`. Nätet i körningen höjde till destructive. I trädet är samma kommando caution. JSONL-filen är inte gjord om. Resten är de fyra stavningarna.

gpt-4.1, sju. `list-top-dirs` tar med `..` `unpack-sample` saknar `-p`. `truncate-notes` är `> notes.txt` och stannar fel även justerat. Samma två `ps` och samma två `curl`, men `ps -u $USER` ingår inte i den justerade träffen.

Urklipp finns redan

aichat har `copy` bredvid `execute`, och förvalstangenten är `e`. yaak har `--copy`.

Urklipp är inte unikt. Ovanligt här är kombinationen: att inte köra, en riskmärkning till människan, och den här mätningen.

yaak namnger `rm`, `dd`, `chmod 000` och en fork-bomb. Listan namnger inte `find -delete` eller `truncate`. Den lilla modellen flaggade båda i mätningen.

Påståenden om `ask`, `genie-cli`, `qx` och `owo` är strukna. De gick inte att belägga.

Kan en sandbox vara säkrare?

Ja, när den är på. Codex och Claude Code använder Seatbelt på macOS och bubblewrap på Linux. Ett kommando i Seatbelt är mer inneslutet än ett inklistrat kommando.

Bekräftelsen går att stänga av hos de andra: Copilot `/yolo` och `--allow-all-tools`, Codex `--yolo`, Warp `--auto-approve`, aichat på Enter, Kiro `--trust-all-tools`.

En sandbox skyddar inte filerna i arbetsytan. `find . -delete` där filerna ligger träffar ändå.

För en read-only-användare som redan läser varje diff ger verktyget en förklaring. Förslaget kan klistras in i ett skal under `sandbox-exec`.