bashagent

Klartext in. Ett kommando, en förklaring och en riskmärkning ut.

Verktyget kör aldrig kommandot.

Mätning 19 oktober 2026. `gpt-4.1-mini` mot `gpt-4.1`. 40 uppgifter, GNU, temperatur 0.

Resultat

	gpt-4.1-mini	gpt-4.1
Höll på det som jämfördes	35/40	33/40
Nya anrop	35	35
Från cache	5	5
Betalt den här körningen	0,012 USD	0,062 USD

Fem procentenheter. Den billiga var före och kostade ungefär en femtedel.

Skillnaden mellan modellerna är inte statistiskt säkerställd. Vid 40 uppgifter är en skillnad under ungefär 15 procentenheter inte skiljbar från brus.

Hela API-kostnaden, med rökkörningen, ligger runt 0,09 USD.

Upplägg

Läsande uppgifter kördes i varsin Debian-container. Utdata jämfördes.

Destruktiva kommandon kördes inte.

Övriga jämfördes som text mot facit. Samma kommando med annan stavning räknas då som avvikelse.

Hypoteserna skrevs innan första mätanropet. Huvudsiffran gäller GNU. macOS är inte mätt.

Felanalys

Två avvikelser som betyder något:

- `gpt-4.1` skrev `find . -maxdepth 1 -type d`. Punkten själv kommer med. Facit har `-mindepth 1`.
- `gpt-4.1-mini` skrev `ls -p docs | grep -v /`. Risknätet såg snedstrecket och höjde märkningen till destructive. Falskt larm, inte ett farligt kommando.

Samma kommando, annan stavning. De ska inte redovisas som fel:

- `ps -u $(whoami)` mot `ps -u "$USER"`
- `cmd=` mot `args=`
- `wget` mot `curl -O`
- `> notes.txt` mot `truncate -s 0`

35/40 och 33/40 räknar ändå in dem. Ingen justerad siffra.

Hypoteserna

1. Enkla kommandon, ungefär lika. Stämmer. Båda klarade i stort sett alla `find`.
2. Den lilla tappar på sammansatta. Stämmer inte på totalsiffran. 35 mot 33.
3. Skillnaden blir för liten, och den billiga räcker. Stämmer.
4. Den lilla missar `find -delete` och `truncate`. Stämmer inte. Den flaggade båda, plus `git clean` och `rm`.
5. GNU-flaggor på macOS. Inte mätt.
6. Priset räknas. Stämmer. Ungefär en femtedel.

Urklipp finns redan

`ask` kör aldrig och kopierar på en tangent. `genie-cli` kopierar som standard. `qx`, `owo`, aichat och `yaak` har samma väg.

Urklipp är inte unikt.

Ovanligt i analysen är kombinationen: att inte köra, en riskmärkning till människan, och en publicerad mätning.

`yaak` blockerar `rm` och `dd`. Listan träffar inte `find -delete` eller `truncate`. Den lilla modellen flaggade båda.

Kan en sandbox vara säkrare?

Ja, i ett enskilt kommando, om den är på. Ett kommando i Seatbelt är mer inneslutet än ett inklistrat kommando.

Bekräftelsen går att stänga av hos de andra. Copilots sandbox är av som standard. Codex har `--full-auto` och Full Access. Warps auto-approve kringgår denylistan som standard. aichat kör på Enter. Flaggorna heter `--yolo`, `--allow-all`, `--trust-all-tools`, `-y` och `auto_run`.

En sandbox skyddar inte filerna inuti arbetsytan. Den hindrar kommandot från att lämna katalogen. `find . -delete` i rätt katalog är lika förödande sandboxat.

För en disciplinerad read-only-användare ger verktyget ingen fördel. Bara en förklaring. Förslaget kan fortfarande klistras in i ett skal som redan körs under `sandbox-exec`.