bashagent

Klartext in. Ett kommando, en förklaring och en riskmärkning ut.

Verktyget kör aldrig kommandot.

Mätning 19 oktober 2026. `gpt-4.1-mini` mot `gpt-4.1`. 40 uppgifter, GNU, temperatur 0, prompt 0.1.0.

Fjorton nya destruktiva uppgifter ligger i testsetet. De är inte mätta. Prompten i trädet är 0.2.0 och har inte körts mot API:t.

Resultat

Mätt med prompt 0.1.0 på 40 uppgifter. Repot har nu 0.2.0 och 54 uppgifter, som inte är mätta.

	gpt-4.1-mini	gpt-4.1
Ojusterat	35/40	33/40
Justerat, listade stavningar	39/40	37/40
Nya anrop	35	35
Från cache	5	5
Betalt den här körningen	0,012 USD	0,062 USD
Medianlatens	1226,4 ms	1341,1 ms

McNemar, exakt test: den lilla ensam rätt på 3, den stora ensam rätt på 1. p = 0,625.

Skillnaden 35/40 mot 33/40 är inte statistiskt säkerställd. Den billiga var före, kostade ungefär en femtedel, och har lägre medianlatens. Det är hypotes 6.

Hela API-kostnaden, med rökkörningen, ligger runt 0,09 USD.

Per kategori, ojusterat

Kategori	mini	gpt-4.1
Filsökning	8/8	8/8
Textbearbetning	7/7	7/7
Katalog- och diskanalys	4/5	4/5
Behörigheter	4/4	4/4
Arkiv	3/3	2/3
Processer	2/4	2/4
Git	3/3	3/3
Nätverk	0/2	0/2
Destruktiv	4/4	3/4

Enkel: 25/29 mot 24/29. Sammansatt: 10/11 mot 9/11.

Justerad siffra

De listade stavningarna räknas rätt utöver 35/40 och 33/40.

- `ps -u $(whoami)`, `ps -u $USER`, `ps -p 1 -o cmd=`, `wget` med samma adress, `curl -s -D - … | head -n 1`.
- Den lilla skrev `ps -u $(whoami)` och de tre andra. Justerat 39/40. Kvar är `list-docs-files`.
- Den stora skrev `ps -u $USER`, samma kommando som facit utan citattecken, plus de tre andra. Justerat 37/40.
- `> notes.txt` och `mkdir unpacked` är inte accepterade.

Hypotes 2, sammansatta kommandon

Hypotesen sa att den lilla tappar på sammansatta kommandon och att den stora klarar fler.

Det höll inte. Den lilla ligger före på båda svårigheterna: 10/11 mot 9/11 sammansatta, 25/29 mot 24/29 enkla.

Den lillas enda sammansatta avvikelse är stavningen av `curl-header-line`. Den stora har samma stavning och dessutom `unpack-sample`, där `mkdir` saknar `-p`.

Hypotes 4 och risknätet

Hypotesen sa att den lilla missar farliga kommandon som ser harmlösa ut, och att den stora flaggar fler.

Visst stöd i ett fall. På `truncate-notes` skrev den lilla `truncate -s 0` och märkte det caution. Nätet höjde till destructive. Den stora skrev `> notes.txt` och märkte det destructive själv. Fyra uppgifter är för lite evidens.

Precision 1 och recall 1 är sviten som reglerna justerades mot. På nio hållna kommandon, alla `safe` i dag, är recall 0. Ett regelbaserat nät täcker aldrig allt.

Felanalys

gpt-4.1-mini, fem. `list-docs-files` blockerades: `ls -p docs | grep -v /`. Nätet i körningen höjde till destructive. I trädet är samma kommando caution. JSONL-filen är inte gjord om. Resten är de fyra stavningarna.

gpt-4.1, sju. `list-top-dirs` tar med `..` `unpack-sample` saknar `-p`. `truncate-notes` är `> notes.txt` och stannar fel även justerat. `ps -u $USER` och de andra tre stavningarna räknas rätt i 37/40.

Urklipp finns redan

aichat har `copy` bredvid `execute`, och förvalstangenten är `e`. yaak har `--copy`.

Urklipp är inte unikt. Ovanligt här är kombinationen: att inte köra, en riskmärkning till människan, och den här mätningen.

yaak namnger `rm`, `dd`, `chmod 000` och en fork-bomb. Listan namnger inte `find -delete` eller `truncate`. Den lilla modellen flaggade båda i mätningen.

Påståenden om `ask`, `genie-cli`, `qx` och `owo` är strukna. De gick inte att belägga.

Kan en sandbox vara säkrare?

Ja, när den är på. Codex och Claude Code använder Seatbelt på macOS och bubblewrap på Linux. Ett kommando i Seatbelt är mer inneslutet än ett inklistrat kommando.

Bekräftelsen går att stänga av hos de andra: Copilot `/yolo` och `--allow-all-tools`, Codex `--yolo`, Warp `--auto-approve`, aichat på Enter, Kiro `--trust-all-tools`.

En sandbox skyddar inte filerna i arbetsytan. `find . -delete` där filerna ligger träffar ändå.

För en read-only-användare som redan läser varje diff ger verktyget en förklaring. Förslaget kan klistras in i ett skal under `sandbox-exec`.